2025 – 2026 Bahar Dönemi YZM212 Makine Öğrenmesi Dersi 4. Laboratuvar Ödevi

Uzak Bir Galaksinin Parlaklık Analizi

Astronomi projelerinde **Bayesian Inference (Bayesyen Çıkarım)**, özellikle gözlem verilerinden model parametrelerini (örneğin bir yıldızın kütlesi veya evrenin genişleme hızı) tahmin etmek için altın standarttır.

Amaç: Gürültülü gözlem verilerini kullanarak bir gök cisminin gerçek parlaklığını ve veri setindeki belirsizliği (standart sapma) Bayesyen yöntemlerle tahmin etmek.

Bayesyen çıkarımın astronomide "altın standart" olarak kabul edilmesinin temel nedeni, astronominin laboratuvar ortamında deney yapılamayan, sadece uzaktan gözlemle sınırlı bir bilim dalı olmasıdır. Geleneksel (Frekansçı) istatistiğin aksine Bayesyen yaklaşım, belirsizlikleri yönetmede çok daha esnektir.

1. Teorik Altyapı

Bayes Teoremi, veriler ışığında bir modelin parametreleri hakkındaki bilgilerimizi güncellememizi sağlar:

$$P(\theta|D) = \frac{P(D|\theta)P(\theta)}{P(D)}$$

- $P(\theta|D)$ **(Posterior):** Veriyi gördükten sonra parametreler hakkındaki güncel bilgimiz.
- $P(D|\theta)$ **(Likelihood):** Parametreler doğruysa, bu veriyi gözlemleme olasılığımız.
- $P(\theta)$ **(Prior):** Veriyi almadan önce parametreler hakkındaki ön bilgimiz.
- $P(D)$ **(Evidence):** Verinin toplam olasılığı (genelde normalizasyon sabiti olarak işlev görür).

2. Python Uygulaması

Bu ödevde, popüler emcee kütüphanesini (Markov Chain Monte Carlo - MCMC) kullanarak bir parametre tahmini simülasyonu yapacağız.

Gerekli Kütüphaneler

```
import numpy as np
import matplotlib.pyplot as plt
import emcee
import corner
```

Veri Oluşturma (Sentetik Gözlem)

```
# Gerçek değerler (Doğa tarafından biliniyor,
bizim tarafımızdan değil)

true_mu = 150.0 # Gerçek parlaklık

true_sigma = 10.0 # Gözlem hatası

n_obs = 50  # Gözlem sayısı

# Gürültülü veri oluşturma

np.random.seed(42)

data = true_mu + true_sigma *
np.random.randn(n_obs)
```

Bu değerler, bir simülasyonda "evrenin nasıl çalıştığını" taklit ettiğimiz **kontrol değişkenleridir.**

İşte bu üç değişkenin astronomik ve istatistiksel karşılıkları:

1. true_mu = 150.0 (Gerçek Fiziksel Değer)

Bu, gözlemlediğimiz gök cisminin **hiçbir hata payı olmasaydı ölçeceğimiz "saf" parlaklığıdır.**

- **Astronometrik Karşılığı:** Örneğin, bir uzak galaksinin gerçekte yaydığı foton sayısı veya bir yıldızın standart mum (Standard Candle) olarak kabul edilen mutlak parlaklığıdır.
- **Neden Önemli?** Simülasyon bittiğinde Bayesyen modelimizin bulduğu değer ile bu 150.0 değerini karşılaştırarak, modelimizin ne kadar isabetli olduğunu ölçeriz.

2. true_sigma = 10.0 (Gözlem Gürültüsü / Hata)

Bu, evrenin ve teknolojinin mükemmel olmamasından kaynaklanan **belirsizliktir.**

- **Astronometrik Karşılığı:** Teleskobun sensöründeki ısıl gürültü, atmosferik dalgalanmalar veya aradaki toz bulutlarının sinyali bozmasıdır.
- **Matematiksel Etkisi:** Bu değer ne kadar büyükse, veriler o kadar "saçılmış" olur. 10.0 değeri, verilerimizin çoğunun 150 ± 10 aralığında olacağını söyler. Eğer bu değer 50.0 olsaydı, gerçek parlaklığı bulmak çok daha zor (veya daha fazla veri gerektiren) bir hale gelirdi.

3. n_obs = 50 (Gözlem Sayısı / Örneklem)

Bu, teleskobunuzu o gök cismine kaç kez doğrultup ölçüm aldığınızı ifade eder.

- **Astronometrik Karşılığı:** 50 farklı gece yapılan gözlem veya bir CCD sensör üzerindeki 50 farklı pikselden gelen veri.
- **Bayesyen Bakış Açısı:** Veri sayısı (n) arttıkça, Bayesyen modelin "Posterior" dağılımı daralır. Yani 5 gözlemle yapılan tahmin çok geniş bir belirsizlik aralığına sahipken, 5000 gözlemle yapılan tahmin neredeyse tam olarak 150.0 değerine odaklanır.

Bayesyen Fonksiyonların Tanımlanması

```
# 1. Log-Likelihood (Verinin modele uygunluğu)
def log_likelihood(theta, data):
    mu, sigma = theta
    if sigma <= 0: return -np.inf # Fiziksel olmayan durum
    return -0.5 * np.sum(((data - mu) / sigma)**2 + np.log(2 * np.pi * sigma**2))

# 2. Log-Prior (Parametreler hakkındaki ön bilgilerimiz)
def log_prior(theta):
    mu, sigma = theta
    if 0 < mu < 300 and 0 < sigma < 50: # Geniş ve informatif olmayan bir sınır
        return 0.0
    return -np.inf

# 3. Log-Posterior (Hedef fonksiyonumuz)
def log_probability(theta, data):
    lp = log_prior(theta)
    if not np.isfinite(lp):
        return -np.inf
    return lp + log_likelihood(theta, data)
```

MCMC Örnekleyiciyi Çalıştırma

```
# Başlangıç değerleri
initial = [140, 5]
n_walkers = 32
pos = initial + 1e-4 * np.random.randn(n_walkers, 2)

sampler = emcee.EnsembleSampler(n_walkers, 2, log_probability,
args=(data,))
sampler.run_mcmc(pos, 2000, progress=True)

# Örnekleri toplama (ilk 500 adımı 'burn-in' olarak atıyoruz)
flat_samples = sampler.get_chain(discard=500, thin=15, flat=True)
```

Sonuçların Görselleştirilmesi ve Yorumlanması

Analiz aşamasında "Corner Plot" kullanarak parametreler arasındaki ilişkiyi ve güven aralıklarını görebilirsin.

```
fig = corner.corner(
    flat_samples, labels=["$\mu$ (Parlaklık)", "$\sigma$ (Hata)"],
    truths=[true_mu, true_sigma]
)
plt.show()
```

Ödev Raporu İçin Sorular/Analizler:

1. **Prior Etkisi:** Eğer parlaklık için çok dar bir prior seçseydiniz (örneğin 100-110 arası), sonuç nasıl değişirdi?
2. **Veri Miktarı:** Gözlem sayısını (n_obs) 5'e düşürdüğünüzde posterior dağılımının genişliği (belirsizlik) nasıl etkileniyor?

Sonuçların Analizi ve Karşılaştırma

MCMC simülasyonu sonucunda elde edilen parametrelerin (Posterior Median) gerçek değerlerle (Ground Truth) uyumunu aşağıdaki tablo üzerinden özetleyebiliriz:

Parametre	Gerçek Değer (Input)	Tahmin Edilen (Posterior Median)	%95 Güven Aralığı (±2σ)	Hata (%)
μ (Ortalama Parlaklık)	150.0	149.85*	[147.2, 152.5]	%0.1
σ (Ölçüm Hassasiyeti)	10.0	10.42*	[8.6, 12.8]	%4.2

**Not: Bu değerler simülasyon her çalıştığında küçük farklılıklar gösterebilir. Tabloyu kendi kod çıktındaki değerlerle güncellemelisin.*

5. Uygulama: Simülasyon Sonuçlarının Raporlanması

Bu bölümde, çalıştırdığınız Python kodunun print çıktılarından ve oluşturulan grafiklerden elde ettiğiniz değerleri aşağıdaki tabloya yerleştiriniz.

Not: Her simülasyon rastgele gürültü ürettiği için değerleriniz arkadaşlarınızınkinden farklı olacaktır; lütfen kendi ekranınızdaki sonuçları kullanınız.

5.1. Parametre Karşılaştırma Tablosu

Değişken	Gerçek Değer (Girdi)	Tahmin Edilen (Median)	Alt Sınır (%16)	Üst Sınır (%84)	Mutlak Hata
μ (Parlaklık)	150.0				
σ (Hata Payı)	10.0				

Tabloyu doldurmak için kod çıktınızdaki "Median" ve "Belirsizlik (+/-)" değerlerini kullanınız.

6. Sonuçların Bilimsel Yorumu (Analiz Soruları)

Tablonuzdaki verileri ve oluşturduğunuz **Corner Plot** grafiğini analiz ederek aşağıdaki soruları yanıtlayınız:

6.1. Merkezi Eğilim ve Doğruluk (Accuracy) Analizi

Bayesyen çıkarım yönteminiz, veri setindeki gürültüye (gürültü oranı %6-7 civarı olmasına rağmen) rağmen gerçek 150.0 değerine ne kadar yaklaştı? Elde ettiğiniz "Mutlak Hata" miktarını göz önüne alarak modelin doğruluğunu yorumlayınız.

6.2. Tahmin Hassasiyeti (Precision) Karşılaştırması

Tablonuzu incelediğinizde; Parlaklık (μ) parametresinin hata payının (güven aralığı genişliği), Ölçüm Hassasiyeti (σ) parametresine göre daha dar (daha hassas) olduğunu göreceksiniz.

Soru: İstatistiksel olarak neden ortalamanın (μ) tahmini, varyansın (σ) tahmininden daha "kesin" (precise) sonuçlar vermektedir? Veri sayısı (n=50) bu durumu nasıl etkilemiştir?

6.3. Olasılıksal Korelasyon Analizi

Ürettiğiniz **Corner Plot** üzerindeki iki parametrenin kesiştiği "elips" şeklindeki dağılıma bakınız. Bu dağılımın şekli bize Parlaklık tahmini ile Gözlem Hatası tahmini arasında bir bağımlılık olup olmadığı hakkında ne söyler? (Eğer elips dik duruyorsa bağımsızlık, eğik duruyorsa korelasyon vardır).

Ödev Teslim Kuralları:

Jupyter Notebook ile çalışılacaksa (önerilien) dosyalar .py uzantılı olmayabilir. README.md dosyası problem tanımı, veri, yöntem, sonuçlar ve yorum / tartışma kısımları kısa ve net şekilde anlatmalıdır. Oluşturduğunuz grafikler ve yorumlarını pdf olarak git projenize ekleyiniz.
Gönderim son tarihi 12.03.2026 24.00 olup ödev teslimi git hesabınız üzerinden olacaktır. 4. Ödev için git adresiniz aşağıdaki Google sheet'e ekleyiniz.
https://docs.google.com/spreadsheets/d/1naYjEiRkv0-EB_YMcdlinJ_CnHz46Gv_RnwyJVAwLnQ/edit?usp=sharing

Astronomların neden bu yöntemi tercih ettiğine dair temel teknik gerekçeler:

1. Ön Bilgilerin (Priors) Kullanımı

Astronomide hiçbir gözlem sıfırdan başlamaz. Örneğin, yeni keşfedilen bir yıldızın kütlesini ölçerken, elimizde yıldız evrimi teorilerinden gelen milyarlarca yıllık bilgi birikimi vardır.

- **Avantaj:** Bayesyen yöntem, önceki çalışmaların sonuçlarını (Prior) matematiksel olarak modele dahil eder. Eğer bir parametrenin (örneğin evrenin yaşı) fiziksel olarak negatif olamayacağını biliyorsak, Bayesyen yaklaşım bunu en baştan modele "enjekte" eder.

2. Karmaşık Belirsizlik Yapıları

Gök cisimlerinden gelen sinyaller; kozmik tozlar, atmosferik bozulmalar ve teleskop gürültüsü gibi pek çok katmandan geçer.

- **Avantaj:** Bayesyen çıkarım, bu gürültü kaynaklarını (nuisance parameters) modelin içine hapsedip, onları **marginalization (marjinalleştirme)** denilen bir işlemle yok ederek sadece ilgilendiğimiz parametreye odaklanmamızı sağlar.

3. Küçük Veri Setleri ve Düşük Sinyal/Gürültü Oranı (SNR)

Uzak bir galaksiden sadece birkaç foton alabildiğimiz durumlarda geleneksel istatistiksel yöntemler (p-değerleri gibi) genellikle yanıltıcı olur.

- **Avantaj:** Bayesyen yöntem, veri seti ne kadar küçük olursa olsun, bize bir "en iyi tahmin" ile birlikte bu tahminin ne kadar güvenilir olduğunu gösteren tam bir **olasılık dağılımı** sunar.

4. Model Karşılaştırma (Occam'ın Usturası)

"Bu gözlemlediğim şey yeni bir gezegen mi yoksa sadece yıldızdaki bir leke mi?" Astronomide bu tür sorular çok kritiktir.

- **Avantaj: Bayesian Evidence (Bayes Faktörü)** kullanarak iki farklı modelin veriyi açıklama başarısını doğrudan karşılaştırabiliriz. Bayesyen yaklaşım, gereksiz yere karmaşık olan modelleri doğal olarak cezalandırır.